

## 딥러닝 기반 자연어처리 기법의 최근 연구 동향 정리 2

ratsgo's blog 글을 정리하였습니다.

### 5. Recursive Neural Networks

자연어는 단어와 단어가 계층적인 방식으로 구(phrase)로 결합되는 재귀적인(recursive) 구조를 나타냄

이러한 구조는 문장 구성성분 분석 트리(consistency parsing tree)로 표현될 수 있음

문장의 문법적 구조 해석을 보다 용이하게 하기 위해 트리 구조 모델이 사용됨

*Socher et al. (2013)*: 구문(phrase), 문장 수준 감성 예측에 이 모델 적용

파싱 트리의 모든 노드(단어)에 대해 감성 스코어를 시각화함

전체 문장의 감성 예측에 큰 영향을 미치는 'not' 또는 'but' 같은 단어에 대한 모델의 민감도가 나타남

감정분석과 문장 관련성 테스트에서 linear LSTM 모델보다 개선됨

### 6. 강화학습과 비지도학습

#### A. 문장생성을 위한 강화학습

강화학습(Reinforcement Learning)은 보상(reward)을 얻기 전에 행동(action)을 수행하도록 에이전트(agent)를 학습시키는 기법임.

*Paulus et al. (2017)*: 기존의 지도 학습 기반의 단어 예측 기법과 강화학습을 결합한 생성요약(abstractive summarization) 모델을 제안.

RNN 에서 단어 수준의 최대 우도 전략의 문제점: 추론 과정에서 이전 토큰은 모델 자체에서 생성된 토큰으로 대체되어 노출 편향이라고 불리는 학습과 추론 사이의 불일치.

학습 목표가 테스트 측정지표와 다르다는 사실.

기계번역, 대화시스템 등을 평가하는 데 쓰이는 측정지표(BLUE, ROGUE)가 단어 수준 학습 전략으로 어떻게 최적화될 수 있는지 분명하지 않음.

강화학습은 위의 문제를 어느정도 해결할 수 있는 잠재력 제공.

*Ronzato et al. (2015)*: 시퀀스 생성 작업(텍스트 요약, 기계번역, 이미지 캡셔닝)을 위한 RNN 기반의 모델을 학습시키기 위해 강화학습 알고리즘 적용. 이전의 지도학습 기법과 비교해 개선을 이끌어냄.

에이전트가 시퀀스의 끝에 도달하면 보상을 받음. 수행할 태스크에 맞게 연구자가 정의할 수 있음.

*Li et al. (2016b)*: 생성 문장에 대해 3 가지 보상(응답의 용이성, 정보 흐름 및 의미의 일관성)을 정의함

다른 접근법. GAN 사용.

생성기(generator)의 학습 목표는 생성된 시퀀스와 진짜 시퀀스를 구별하도록 학습된 다른 판별자(discriminator)를 속이는 것. 생성기 G 와 판별자 D 는 min-max 게임에서 함께 학습되며, 생성기는 판별자가 실제 시퀀스와 구별할 수 없는 시퀀스를 생성함.

특정 자극(이미지 캡셔닝에서의 소스 이미지 등)을 조건으로 하는 GAN 의 변형으로도 볼 수 있음

## B. 비지도학습 기반 문장 표현

문장에 대한 분산표상 (distributed representation): 단어 임베딩처럼 비지도 방식으로 학습 가능.

비지도학습의 결과는 임의의 문장을 의미와 문법적 속성이 내재한 고정 크기의 벡터에 매핑하는 문장 인코더.

Kiros et al. (2015): 문장 임베딩을 위한 skip-thought 모델

주어진 문장 앞뒤에 있는 두 개의 인접 문장 예측. Seq2seq 모델 사용.

문장 분류(sentence classification) 문제로 학습된 문장 인코더의 품질을 검증함.

## C. 심층생성모델

잠재코드공간(latent code space)에서 실제 문장을 생성하면서 자연어의 풍부한 구조를 발견

VAN 과 GAN 의 최근 연구 검토

표준적인 오토인코더는 자연어 문장 생성에 실패함 b/c 잠재공간(latent space)에 어떤 제약도 가하지 않기 때문.

VAE: 적절한 샘플을 뽑을 수 있도록 하는 히든 코드 스페이스에 사전 분포를 부과함. 결정론적 인코더 기능을 학습된 사후확률 인식 모델로 대체함으로써 오토인코더 아키텍처를 수정함. 모델은 데이터를 잠재표현으로 인코딩하는 인코더와 잠재공간에서 샘플을 생성하는 생성자 모델로 구성됨.

GAN: 생성모델의 다른 종류임. 두 가지 경쟁 네트워크로 구성됨. 생성자 네트워크는 잠재공간에서 데이터 인스턴스로 잠재 표현을 인코딩함. 판별자 네트워크는 실제 데이터와 생성자가 만든 인스턴스를 구별하기 위해 생성자와 동시에 학습함.

*Zhang et al. (2016)*: 실제 텍스트를 생성하기 위한 적대적인 학습에 LSTM 과 CNN 을 적용한 프레임워크를 제안.

심층학습모델 평가: 텍스트의 경우 고정된 문법 규칙으로 학습 데이터 만든 다음, 생성된 샘플이 미리 정의된 문법과 일치하는지 여부로 생성모델 평가.

또 다른 전략은 학습에 쓰지 않은 양의 테스트 데이터에서 샘플의 BLEU 점수를 평가해 보는 것. 학습에 쓰지 않은 실제 데이터와 유사한 문장을 생성하는 능력은 모델의 품질 척도로 간주됨.

## 7. 메모리 네트워크

어텐션 메커니즘은 인코더에서 만들어진 히든 벡터(hidden vector)들을 저장

디코더는 각 토큰을 생성하고 있는 중에 이 벡터들에 액세스 가능

인코더의 히든 벡터들은 모델의 내부 메모리 항목으로 볼 수 있음

모델이 상호작용할 수 있는 메모리의 형태로 뉴럴 네트워크들을 연결하는 것에 대한 관심 급증

*Weston et al. (2014)*: 질의응답을 위한 메모리 네트워크 제안

일련의 진술은 질의를 잠재적으로 뒷받침하는 사실로써 모델에 입력됨

모델은 질의와 이전에 검색한 메모리를 기반으로 한 번에 하나의 항목을 검색하도록 학습됨

Sukhbaatar et al. (2015): 메모리 항목이 어텐션 메커니즘을 통해 soft 한 방식으로 검색되어 end-to-end 학습을 가능하도록 하는 end-to-end memory network 를 제안

언어 모델링을 위한 모델의 특별한 사용법 보여줌. 문자의 각 단어는 메모리 항목들로 간주됨. 멀티홉을 사용하여, 모델은 deep LSTM 모델에 필적하는 결과 산출